

01

SECTION 01

RAG 아키텍처 설계


검색으로 LLM의 세 가지 한계 보완

AI SERVICE ARCHITECT / 2026 / 1H 30M

— LEARNING GOALS

오늘의 목표

- 엔터프라이즈 RAG 5계층 설명 가능
- 각 계층의 Trade-off 식별 가능
- Hybrid / Reranker 도입 타이밍 판단 가능
- 모델·DB 선택 근거 제시 가능



CHAPTER 1 / 6

01 / 6

왜 **RAG**가 필요한가?

이 챕터에서 답할 질문

- LLM의 3가지 구조적 한계는 무엇인가?
- 각 한계가 실제 사고로 어떻게 번지는가?
- RAG는 정확히 무엇이고 어떻게 한계를 푸는가?
- Fine-tuning vs RAG 의사결정 기준

— WHY RAG

LLM의 세 가지 구조적 한계

01

KNOWLEDGE CUTOFF

학습 시점 이후의 데이터 부재

02

HALLUCINATION

근거 없는 답을 그럴듯하게 생성

03


PRIVATE DATA 부재

회사 내부 문서·DB 미학습

KNOWLEDGE CUTOFF 실무 예시

2024-04 학습 모델에게 Q. "2025년 11월 발표된 OpenAI Realtime API 가격은?"

A. "2024년 4월 이후 정보는 제공할 수 없습니다."



핵심 모델 교체로는 해결 안 됨 — 새 모델도 또 다른 cutoff. RAG의 검색 인덱스만 즉시 갱신 가능.

— EXAMPLE · HALLUCINATION

AVIANCA 판례 사건

2023 · MATA V. AVIANCA · 美 연방법원

- 01 변호사가 ChatGPT로 판례 조사
- 02 ChatGPT가 사건명 · 법원 · 인용번호 포함 6개 판례를 상세 인용
- 03 변호사가 검토 없이 그대로 법원에 제출
- 04 법원 확인 결과 6건 전부 존재하지 않음
- 05 결과: 벌금 \$5,000 + 공개 제재

구조적 경향 LLM은 "모른다"보다 "그럴듯함"을 선호.

— EXAMPLE · PRIVATE DATA

PRIVATE DATA 부재 예시

질문 "김영수 부장 남은 연차 며칠인가요?"

CHATGPT (기본)

- "사내 직원 정보는 확인할 수 없습니다."
- 정상 응답: 학습되지 않은 데이터


CHATGPT + 사내 RAG

- HR DB 검색 → "남은 연차 7일"
- 검색 시점 권한 제어가 필수

보안 관점 OpenAI의 사내 DB 학습 시 더 큰 보안 사고.

— DEFINITION

RAG란 정확히 무엇인가



— DECISION #1

첫 번째 의사결정

FINE-TUNING VS RAG

	FINE-TUNING	RAG
접근 방식	모델 자체를 재학습	외부 지식을 검색해 주입
바꾸는 것	모델의 가중치	검색 인덱스
적합한 문제	스타일·톤·형식	사실·최신성
근거 제시	어려움	원문 인용 가능

— DECISION #1 · RESOURCE VIEW

자원·비용·운영 관점

	FINE-TUNING	RAG
초기 비용	학습 GPU · 데이터셋 구축 수백만~수천만원	문서 인덱싱 수십만원 수준
업데이트	재학습 (수시간~수일)	인덱스 갱신 (수분)
거버넌스	모델에 내재 삭제·감사 어려움	검색 단계 필터·권한 제어
팀 역량	ML 엔지니어 필요	백엔드·DevOps로 가능

CHAPTER 2 / 6

02_{/6}

RAG 5계층 & 파이프라인

이 챕터에서 답할 질문

- 엔터프라이즈 RAG의 5계층은 무엇인가?
- Index Time과 Query Time이 한 그림에 어떻게 모이는가?
- 이후 4개 챕터는 5계층의 어디를 다루는가? (로드맵)

— ARCHITECTURE

엔터프라이즈 RAG의 5계층

[5] LLM INTEGRATION & RESPONSE

[4] RETRIEVAL PIPELINE · Hybrid + Reranker

[3] EMBEDDING MODEL · 언어 · 길이 · 비용


[2] CHUNKING & INDEXING · fixed · recursive · semantic

[1] DATA INGESTION · parsing · OCR · metadata

[0] GOVERNANCE · OBSERVABILITY · EVALUATION (cross-cutting)

— PIPELINE

RAG 기본 프로세스 한 장



CHAPTER 3 / 6

03 / 6

LAYER 1-2 — PARSING & CHUNKING

이 챕터에서 답할 질문

- Parsing 계층이 왜 가장 과소평가되는가?
- 문서 타입별 Parsing 도구·접근법은?
- **Chunking 4 전략**을 어떻게 매칭하는가?
- Chunk 크기·Overlap·메타데이터는 어떻게 설계하는가?

— LAYER 1 — INGESTION

가장 과소평가되는 계층

PARSING의 함정

- PDF — 레이아웃(표·다단) 보존
- HTML — boilerplate 제거
- 이미지 — OCR + 캡셔닝

도구

- Unstructured
- LlamaParse
- Azure Document Intelligence
- pymupdf

— LAYER 1 — LOSS VISUALIZATION

어떻게 정보가 사라지는가

원본 PDF

연도	항목	매출
2022년	소프트웨어	8천만
2023년	소프트웨어	1억
2024년	소프트웨어	1.3억

PARSE

단순 텍스트 추출

연도 항목 매출
2022 소프트웨어 8천 년 웨어 만
2023 소프트웨어 1 년 웨어 억
2024 소프트웨어 1.3 년 웨어 억
→ 행·열 경계가 사라짐

원본 · 2단 편집

계약 제1조
본 계약은 갑과 을
사이의 소프트웨어
공급에 관한
사항을 규정한다.

계약 제2조
갑은 을에게
계약금액을 계약
체결일로부터
30일 이내 지급한다.

PARSE

좌·우 단이 뒤섞임

계약 제1조 계약 제2조
본 계약은 갑과 을 갑은 을에게
사이의 소프트웨어 계약금액을 계약
공급에 관한 체결일로부터
사항을 규정한다. 30일 이내 지급한다.

— PARSE · STRATEGY

PARSING의 3가지 접근법

01

SIMPLE TEXT

pdfplumber · PyPDF2 · BS4

비용 ≈ \$0 · ms 단위

표·레이아웃 파괴, OCR 없음 — 단일 컬럼 텍스트용

02

LAYOUT-AWARE

Unstructured · Docling · Marker

페이지당 수 초 · OSS 연산 비용

2단·표 구조·헤딩 인식 — 일반 기업 문서 80%

03

LLM · VISION

LlamaParse · Azure DI · GPT-4V · Mistral

OCR

페이지당 \$0.003~\$0.03

스캔본·복잡 표·다이어그램 — 고품질 요구용

2026년 PARSING 도구 비교

도구	강점	약점	적합 상황
Unstructured OSS/SaaS	표 정확도 1위 (0.84) 토큰 노이즈↓	페이지당 수 초 처리 속도 느림	혼합 문서 · 품질 우선
LlamaParse SaaS	속도 일정 ~6s 복잡 표·OCR 내장	데이터 외부 전송 페이지당 과금	클라우드 OK · 속도 우선
Docling OSS · IBM	계층 구조 보존 메타데이터 풍부	단순 문서엔 오버킬	위키 · 매뉴얼 · 구조 보존
Marker OSS	속도 최고 가벼운 의존성	복잡 표 셀 분할 오류	단순 구조 · 대량 배치

실전 조언 완벽한 단일 도구 부재. 현실 해법은 하이브리드 파이프라인.

— PARSE · DECISION TREE

문서 타입별 의사결정 트리

- Q1** 이미지 스캔본? (텍스트 레이어 없음)
→ OCR 필수 · LlamaParse · Azure DI · Mistral OCR
- Q2** 표·그래프가 핵심 정보원?
→ 표 정확도 우선 · Unstructured or Docling
- Q3** 2단 편집 · 사이드바 · 다단계 헤딩?
→ Layout-aware · Docling or Marker
- Q4** 단일 컬럼 깔끔한 텍스트
→ pdfplumber · Unstructured "fast" — 비용·속도 최적

품질 검증 파이프라인 세팅 후 랜덤 10페이지 사람 검수 필수.

— LAYER 2 — CHUNKING

CHUNKING 4 전략

전략	설명	노트
Fixed-size	N 토큰씩 자름 (+overlap)	저렴·단순, 문맥 파괴
Recursive	단락→문장→단어 계층	★ 기본 권장 · 85~90% recall
Semantic	의미 유사도 경계	recall 91~92%, 비용↑
Document-aware	MD · 코드 · 표 구조	구조적 문서에 강함

— CHUNK · BY TYPE

문서 타입별 **CHUNKING** 매칭

문서 타입	추천 CHUNKING	이유
Markdown · HTML	Header-based + Recursive	H1/H2 = 완결 아이디어, 구조가 이미 경계
소스 코드	AST Function-aware	함수 단위 = 논리 단위, 중간 자르면 맥락 상실
계약 · 법령	Clause-based (Parent-Child)	작은 조항으로 검색, 주변 조항으로 컨텍스트
FAQ · API 문서	Entry-based	Q&A · endpoint는 쪼개면 의미 손상
장문 리포트 · 에세이	Recursive 512 (+ Semantic)	벤치마크 1위 (69%) · 대부분의 기본값
표 · Excel	Row-based or Table Summary	각 행이 독립 의미, 큰 표는 요약+상세

2026 표준 단일 전략으로 모든 문서 처리 금지. 표준은 Hybrid Chunking.

CHUNK크기 · OVERLAP 튜닝 프로세스

STEP 1 · 기본값 출발

- Chunk 512 tokens
- Overlap 10~25% (51~128)
- 전략 Recursive

STEP 2 · 베이스라인 측정

- Golden Dataset 준비
- Recall@5 · MRR · nDCG 기록
- "출발선" 확정

STEP 3 · 변수 1개씩 변경

- 크기 256 · 512 · 1024
- Overlap 0% · 10% · 25%
- 전략 Recursive ↔ Semantic

STEP 4 · 타입별 개별 튜닝

- 법령 256
- 매뉴얼 1024
- FAQ entry-based

벤치마크 근거 Vectara 2026 · Recursive 512 = **69% (1위)** · Azure 권장 512+25% · Adaptive
87% vs Fixed 13% · Chunking이 임베딩 모델만큼 **영향력 큼** (NAACL 2025).

— METADATA · TAGGING

메타데이터 태깅 실전 설계

T1

항상 필수

doc_id · doc_type · chunk_index ·
source_path · created_at ·
updated_at

T2

엔터프라이즈 필수

access_tags · version · language
· embedding_model

T3

검색 품질 향상

section_title · page_number ·
bbox · summary

경고 나중에 추가 시 전체 재인덱싱 필수. 처음부터 스키마에 포함.

CHAPTER 4 / 6

04_{/6}


LAYER 3 — EMBEDDING

이 챕터에서 답할 질문

- 임베딩이란 정확히 무엇인가?
- 2026년 주요 임베딩 모델 비교 (MTEB 기준)
- 임베딩 모델 선택의 4가지 질문
- 모델 교체 비용을 설계에 어떻게 포함하는가?

— LAYER 3 — DEFINITION

임베딩이란 정확히 무엇인가



1536 DIMENSIONS · COSINE SIMILARITY

— LAYER 3 — EMBEDDING

임베딩 모델 비교 (MTEB)

모델	MTEB	컨텍스트	강점
Cohere embed-v4	65.2	128k	다국어(한국어)·긴 문서
OpenAI text-embed-3-large	64.6	8k	영어 범용 기준점
BGE-M3 (OSS)	63.0	8k	셀프호스팅·1000+ 언어

— DECISION FRAMEWORK

벤치마크보다 먼저 답할 4 질문

- Q1** 데이터 언어는? → 한국어 비중 크면 Cohere v4 / BGE-M3
- Q2** 문서 길이는? → 계약서·백서면 128k 컨텍스트 유리
- Q3** 호스팅 정책은? → 외부 전송 불가면 BGE-M3 셀프호스팅
- Q4** 차원 × 건수 = 스토리지 비용 → 3072차원 · 1M = VectorDB 청구서

— MIGRATION COST

임베딩 모델 교체 = 전체 인덱스 재구축

리스크 수천만 건이면 며칠 소요. 설계 시점에 교체 비용 반드시 추정.

해결 메타데이터에 `embedding_model_id` 저장 → 이중 쓰기 + 점진 마이그레이션.

CHAPTER 5 / 6

05_{/6}

LAYER 4 — RETRIEVAL (QUERY TIME)

이 챕터에서 답할 질문

- VectorDB는 정확히 무엇을 하는가? (ANN · HNSW · IVF-PQ)
- 2026년 4대 VectorDB는 어떻게 다른가?
- 왜 벡터 검색 단독으로 부족한가? (Hybrid · BM25)
- RRF로 두 검색 결과를 어떻게 합치는가?
- Reranker는 왜 프로덕션의 기준선인가?

— LAYER 4 — STORAGE

VECTORDB는 ANN을 한다

전통 DB

- WHERE id = 42
- 정확 매치 (Exact match)
- B-Tree · Hash

VECTORDB

- 고차원 공간의 유사 벡터
- 근사 최근접 이웃 (ANN)
- HNSW (기본) · IVF-PQ

— OPTIONS · 2026

VECTORDB 4 옵션

01

PINECONE

관리형. API Key 한 줄로 시작.
70% 관리형 점유율.

02

QDRANT

Rust. p50 ≈ 4ms. 풍부한
payload 필터.

03

WEAVIATE

Hybrid Search 1-쿼리 내장. 모듈
식 벡터라이저.

04

PGVECTOR

Postgres 확장. HNSW 지원. 트랜
잭션 일관성.

— LAYER 4 — RETRIEVAL

DENSE만으로는 부족

DENSE (VECTOR)

- 의미 유사성에 강함
- 정확 토큰 매칭 약함

SPARSE (BM25)

- 정확 매칭에 강함
- 의미 유사성 약함

— LAYER 4 — SPARSE · BM25

BM25는 어떻게 점수를 매기는가

$$\text{BM25} = \text{TF} \times \text{IDF} \times \text{LENGTH-NORM}$$

01

TF · 빈도

많이 나오면 점수 ↑

Doc A · 검색어 3회

Doc B · 검색어 1회

Doc C · 검색어 0회

→ Doc A 점수 ↑↑↑

02

IDF · 희귀도

희귀할수록 가치 ↑

"the" 흔함 → IDF ↓

"가격" 보통 → 중

"AX-2045-R" 희귀 → ↑↑

→ 코드·고유명사가 강한 신호

03

LENGTH NORM


긴 문서 보정

짧은 문서 + 1회 → 강한 신호

긴 문서 + 1회 → 우연 가능 (보정)

한 줄 BM25는 토큰 단위 정확 매칭에 강하지만 의미는 모름 — Dense와 짝을 이뤄야 합니다.

HYBRID SEARCH · 두 검색을 합친다



— 언제 HYBRID가 필수인가

01 제품 코드 AX-2045-R · 시리얼·SKU	02 법령·규정 조항 §14(2) · 시행규칙 23조	03 의약품·검사 코드 ICD-10 E11.9 · KCD 코드	04 약어·고유명사 SLA · API · MLOps · 사내 코드네임
--	---	--	--

기업 문서엔 **고유명사·코드·약어**가 한가득. Dense 단독은 이 토큰들을 흘려보냅니다.

— LAYER 4 — RERANK

왜 **RERANKER**인가

RETRIEVAL Recall

- 넓게 캐스팅 (top 50~100)

RERANKER Precision

- 컨텍스트창에 넣을 것만 (top 5~10)

+23.4% **30 → 10%**


BEIR 벤치마크 개선
(COHERE RERANK 3.5)

무관 문단 비율
감소

— RERANKER · HOW & WHEN

RERANKER는 어떻게 작동하고 언제 쓰나

[STAGE 1] RETRIEVE — RECALL



RETRIEVER VS RERANKER

- Bi-encoder · 따로 인코딩, 미리 벡터 저장
- Cross-encoder · 쌍을 함께 인코딩, 더 정밀
- 속도 차이 ~100배 → 2단계 분리 필수

언제 RERANKER가 효과적인가

- Recall은 OK인데 Top-K 노이즈가 많을 때
- LLM 컨텍스트 윈도우 절약 필요
- 답변 품질이 무관 문단에 민감한 도메인 (법무·의료)

— OPTIONS

RERANKER 3카테고리

01**CROSS-ENCODER (OSS)**

jina-reranker-v3 · bge-reranker-v2-m3.
셀프호스팅.

02**MANAGED**

Cohere Rerank 4 (32K ctx) · Voyage Rerank
2.5. SaaS, 다국어 우수.

03**LLM-AS-A-JUDGE**

GPT-5.5 · Claude Opus 4.7로 rerank. 설명↑, 비
용·지연↑.

CHAPTER 6 / 6

06 / 6

LAYER 5 + 평가 + 통합


이 챕터에서 답할 질문

- 5계층을 한 장 참조 아키텍처로 합치면?
- RAG 평가는 왜 단계별로 분리해야 하는가?
- Recall@k · MRR · nDCG는 무엇이 어떻게 다른가?
- Faithfulness · Relevance · Groundedness 셋의 차이

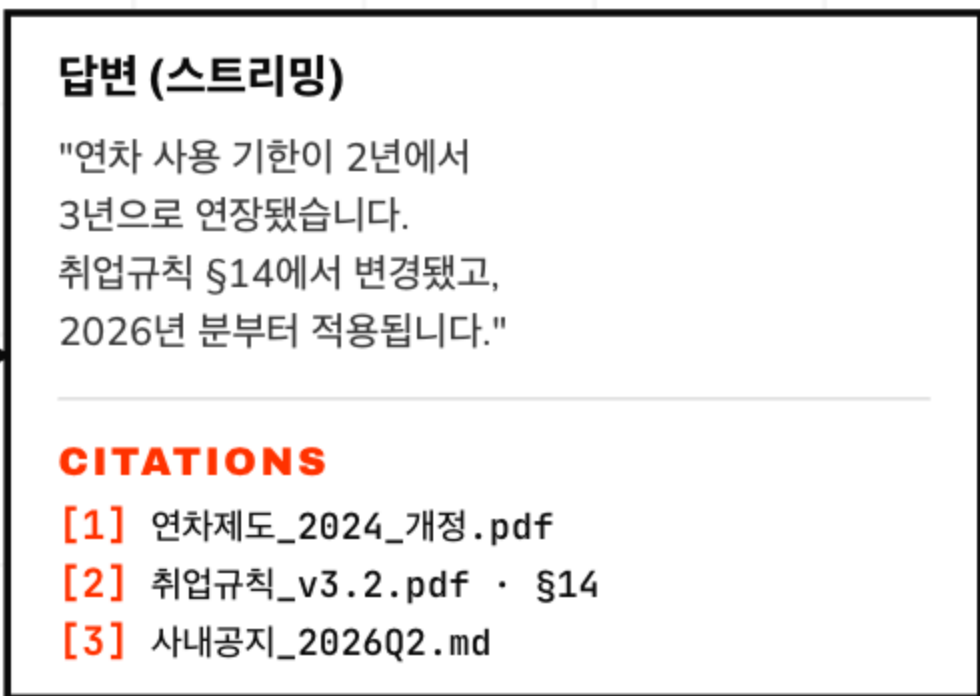
— LAYER 5 — LLM INTEGRATION

검색 결과를 답변으로

[1] PROMPT ASSEMBLY



[2] RESPONSE



01

PROMPT 템플릿

System · Context · Query 분리 ·
"컨텍스트 외 추론 금지" 지시

02

인용 구조

chunk_id ↔ 원문 메타데이터 매핑
→ 답변에 [1] 표기

03

STREAMING

토큰 단위 스트리밍 → 체감 지연 ↓
특히 긴 답변에 필수


04

FAILURE 처리

검색 0건 → "근거 없음" 안전 거절.
Hallucination 방지의 마지막 게이트.

— REFERENCE ARCHITECTURE

엔터프라이즈 RAG 통합도



— LAYER 0 — CROSS-CUTTING

측정 없이는 개선도 없다

RETRIEVAL 지표

- Recall @ k
- MRR
- nDCG

GENERATION 지표

- Faithfulness (근거성)
- Answer Relevance
- Groundedness

METRIC · RETRIEVAL

검색 지표 **RECALL@K · MRR · NDCG**

질문 "2024년 개인정보보호법 몇 조가 개정됐나요?"

정답 문서: **Doc-A** (법령집_2024_개정판.pdf)

시스템	상위 5개 순위	RECALL@5	MRR	NDCG@5
System X	Doc-C, Doc-A , Doc-F, Doc-B, Doc-D	1	0.50	0.63
System Y	Doc-A , Doc-B, Doc-C, Doc-D, Doc-E	1	1.00	1.00
System Z	Doc-B, Doc-C, Doc-D, Doc-E, Doc-F	0	0	0

해석 Recall: 누락 여부 · MRR/nDCG: 순위 품질. Recall↓ → 검색 고장, MRR↓ → Reranker 약함.

— METRIC · GENERATION

생성 지표 FAITHFULNESS · RELEVANCE · GROUNDEDNESS

질문 · 문서 "연차 제도 개정 내용 알려줘"

문서: 연차제도_2024_개정.pdf (사용 기한 2년 → 3년 연장)

답변	FAITHFULNESS	RELEVANCE	GROUNDEDNESS
A. "2년에서 3년으로 연장됐습니다"	✓	✓	✓
B. "연차는 소중한 권리입니다"	✓	✗	✗
C. "5년으로 늘어났어요"	✗	✓	✗

원인 분리 Faithfulness↓ 프롬프트/모델 · Relevance↓ 질문 해석 · Groundedness↓ 인용 구조.

CLOSING · WRAP-UP

END

체크리스트 & Q&A

이 마무리에서 하는 일

- 6 챕터를 한 줄로 답할 수 있는지 자가 점검
- RAG 5계층을 말로 설명할 수 있는지 확인

— SECTION 1 · WRAP-UP

아키텍트 체크리스트

☐ RAG 5계층 설명 가능

☐ Fine-tune vs RAG 기준 3가지

☐ 조직 언어·문서에 맞는 임베딩 정당화

☐ Hybrid가 필요한 문서 유형 3가지

☐ Reranker의 비용·이득 수치

☐ Golden Dataset 없이 개선 불가 이유

QUESTIONS ?